

Predictia Bolilor Cardiovasculare

Sistem de Suport Decizional bazat pe Machine Learning

Motivația Personală: Acest proiect reprezintă o bună metodă pentru a practica machine learning, creând un model de aplicatie ce poate salva vieți prin trierea rapidă a pacienților cu risc ridicat (17.9M decese anual la nivel global).

Setul de Date Cleveland


Contextul Proiectului

 **Sursa:** UCI Machine Learning Repository (Cleveland).

 **Dimensiune:** 297 instanțe procesate (pacienți).

 **Tip:** Învățare supervizată – Clasificare binară.

 **Target:** 0 = Sănătos, 1 = Prezența bolii.



| Atribute și Preprocesare

Semnificația Câmpurilor

cp: Tip durere (1-4)

trestbps: Tensiune în repaus

thalach: Ritm cardiac maxim

ca: Vase colorate fluoroscopic

thal: Defect (normal, fix, reversibil)

Prelucrări Aplicate

- Eliminarea valorilor lipsă (marcate cu '?').
- Binarizarea variabilei țintă (Target).
- **Standardizarea:** StandardScaler pentru atribute continue (vârstă, colesterol).
- Împărțirea Train/Test: 80% / 20%.

Metodologie și Algoritmi




Regresia Logistică

Cel mai simplu model. Calculează probabilitatea bolii bazându-se pe importanța fiecărui simptom în parte.



Random Forest

Creează o sută de arbori de decizie care votează diagnosticul final, fiind foarte robust la erori



SVM (Finalist)

Găsește granița geometrică optimă de separare între pacienți, oferind cea mai mare siguranță în diagnostic.

Performanțele Modelelor




Explicabilitatea

Corelații

Folosind SHAP Values, am validat că modelul a învățat tipare fiziologice reale:

- **Factori de Risc:** Anomalii EKG, vase colorate (ca) și defecte taliu (thal).
- **Factori de Protecție:** Ritm cardiac maxim ridicat (thalach) atins în efort.

ST segment depression





Concluzii

Limitări: Setul Cleveland este de dimensiuni reduse (303 pacienți). Rezultatele sunt promițătoare, dar necesită validare pe date moderne (ex: CDC dataset).

Posibile optimizari: Cresterea preciziei corectand erori pe cazuri individuale.

Referințe Științifice

- Detrano, R., et al. (1989). CAD Diagnosis. Am J Cardiol.
- Breiman, L. (2001). Random Forests. Machine Learning.
- Cortes, C., & Vapnik, V. (1995). SVM. Machine Learning.
- Lundberg, S. M. (2017). SHAP Values. NIPS.
- Hosmer Jr, D. W., et al. (2013). Applied Logistic Regression.
- Mohan, S., et al. (2019). Heart disease prediction. IEEE Access.
- Topol, E. J. (2019). High-performance medicine. Nature Med.
- Amann, J., et al. (2020). XAI in Healthcare. BMC Med Inform.
- Bergstra, J. (2012). Hyper-parameter optimization. JMLR.
- Latha, C. (2019). Ensemble techniques for CVD. Informatics Med.